Projet sur l'analyse univariée et les tests statistiques

Merci de lire attentivement les consignes ci-dessous et de les respecter.
Ce projet est à réaliser en binôme avec le logiciel `R`*. Chaque binôme va travailler sur un fichier distinct. Vous devez télécharger depuis Moodle le fichier de données qui porte le même numéro que celui de votre binôme, dans le dossier* `Fichiers de données pour les projets` *qui correspond à votre numéro de groupe de TP.*
Le projet est à déposer sous Moodle, dans l'espace de dépôt de votre groupe de TP, sous la forme d'un rapport au format `.pdf`*, dont le nom doit contenir les deux noms de votre binôme ainsi que le numéro de votre fichier (ne déposez qu'un fichier par binôme). Ce rapport ne doit pas dépasser 20 pages. Le code* `R` *doit être inséré dans votre rapport dans le corps du texte (et pas en annexe à la fin du rapport). La date limite de remise est le* **dimanche 24 novembre 2024 (jusqu'à minuit) et le dimanche 1er décembre pour les étudiants en alternance**.

Tous les tests sont à réaliser avec un risque α *de 5 %.* **Même si les questions vous incitent à faire un test unilatéral, ne faites que des tests bilatéraux.** *Rappelez pour chaque test les hypothèses nulle et alternative et donner le nom du test utilisé. Donnez et vérifiez les conditions de validité du test, mais si elles ne sont pas « parfaitement » vérifiées, faites quand même le test. Lorsqu'un test statistique est significatif, vous devez préciser le sens de la liaison que vous avez mise en évidence en vous aidant des estimations des paramètres. Ne donnez dans votre rapport que les sorties de* `R` *nécessaires (intégrées au texte) et* **commentez chaque sortie que vous donnez**. *Il sera tenu compte de la présentation et de la rédaction dans la notation.*

Comme on peut le lire sur le portail open data de l'Agence de la transition écologique (ADEME) (`https://data.ademe.fr/datasets/dpe-31`) dont sont issues les données que vous allez analyser, « le diagnostic de performance énergétique (DPE) [dans sa version d'avant juillet 2021] renseigne sur la performance énergétique d'un logement ou d'un bâtiment, en évaluant sa consommation d'énergie et son impact en terme d'émissions de gaz à effet de serre. Le DPE décrit le bâtiment ou le logement (surface, orientation, murs, fenêtres, matériaux, etc.), ainsi que ses équipements de chauffage, de production d'eau chaude sanitaire, de refroidissement et de ventilation. Il indique, suivant les cas, soit la quantité d'énergie effectivement consommée (sur la base de factures), soit la consommation d'énergie estimée pour une utilisation standardisée du bâtiment ou du logement. »

La lecture du DPE est facilitée par deux étiquettes à 7 classes de A à G (A correspondant à la meilleure performance, G à la plus mauvaise) :

- l'étiquette énergie pour connaître la consommation d'énergie primaire,
- l'étiquette climat pour connaître la quantité de gaz à effet de serre émise.

Le diagnostic de performance énergétique doit être établi par un professionnel indépendant satisfaisant à des critères de compétence et ayant souscrit une assurance.

Sont considérés comme « passoires énergétiques » les logements qui sont classés F ou G pour leur consommation d'énergie primaire. En application de la loi de lutte contre le dérèglement

climatique, les loyers de ces logements ont été gelés le 24 août 2022 et, à compter du 1er janvier 2025, les logements classés G ne pourront pas faire l'objet d'un nouveau contrat de location.

Les données

Vous disposez d'un échantillon de 1000 logements, tirés aléatoirement parmi tous les logements individuels de la Haute-Garonne construits entre 1900 et 2020, qui ont eu un DPE avant juillet 2021, et pour lesquels sont renseignées toutes les variables ci-dessous (les logements qui avaient des données manquantes ont été supprimés du fichier) :

- `type_logement` : type du logement (codé 1 pour appartement et 2 pour maison),
- `annee_construction` : année de construction du logement,
- `surface_habitable` : surface habitable du logement (en m^2),
- `type_energie_chauffage` : type d'énergie utilisée pour le chauffage (codé 1 pour gaz, 2 pour électricité et 3 pour autre),
- `conso_energie` : consommation énergétique annuelle, en kilowatts/heure d'énergie primaire par m^2 (kWhEP/m^2),
- `classe_conso_energie` : classe de consommation énergétique (de A à G),
- `emission_ges` : estimation des émissions annuelles de gaz à effet de serre, en kilogrammes équivalent CO_2 par m^2 (Kg éq. CO_2/m^2).

Le but de cette étude (en plus de vous faire pratiquer les tests statistiques) est d'identifier très sommairement quelques facteurs qui sont liés à la consommation énergétique et aux émissions de gaz à effets de serre des logements. Il est évident que beaucoup d'autres variables, présentes dans le fichier initial de l'ADEME (105 variables en tout), jouent aussi un rôle dans ce problème.

1. Faire une introduction en décrivant la population concernée par l'étude, son contexte et son but, la source des données, puis donner les variables de l'échantillon en précisant leur type.
2. Effectuer les transformations nécessaires pour que les variables qualitatives soient identifiées par `R` en tant que telles et leur donner des labels appropriés.
3. A partir de la variable `annee_construction`, créer la variable `anciennete` qui correspond à l'ancienneté du logement au 1er janvier 2021 (on considérera, faute de mieux, que les logements ont été construits le 1er janvier de l'année de leur construction). Cette variable ne sera pas utilisée dans les tests de liaison mais seulement dans le projet sur la régression. Vous devez quand même en faire l'étude descriptive (à la place de la variable `annee_construction`).
4. Etude descriptive univariée

   Commencer l'étude statistique par une étude descriptive de toutes les variables du fichier (une par une). On utilisera bien sûr les variables transformées à la question précédente. Pour chaque variable, décrire sa distribution à l'aide des outils appropriés en fonction de son type (résumés numériques et graphiques). **Ne pas oublier de commenter vos sorties !**

5. En France, en 2020, d'après le site du Ministère de la transition écologique et de la cohésion des territoires (`https://www.statistiques.developpement-durable.gouv.fr/sites/default/files/2022-12/datalab_essentiel_296_conditions_logements_decembre2022_0.pdf`), la surface moyenne des **appartements** était de 65,5 m^2.

   Peut-on considérer que les appartements de la Haute-Garonne de la population étudiée ont en moyenne la même surface que ceux de la France entière en 2020 ? Répondre à la question à l'aide d'un test statistique.

6. Liaisons entre les variables de l'étude

   (a) La classe de consommation énergétique dépend-elle du type de chauffage ?

   (b) La surface habitable des **maisons chauffées à l'électricité** a-t-elle une incidence sur leur consommation énergétique (variable `conso_energie`) ?

   (c) Les émissions de gaz à effet de serre sont-elles les mêmes en moyenne pour les appartement et les maisons ?

   (d) Le type de chauffage et les émissions de gaz à effet de serre sont-ils liés ? Si oui, préciser quelles classes de type de chauffage diffèrent en termes d'émission de gaz à effet de serre.

7. Conclusion de l'étude

   Faire une courte synthèse récapitulant les résultats de votre étude.